Кластеризация изображений по визуальному подобию с помощью вариационных автоэнкодеров

А. С. Коваленко

ЮФУ
Институт математики, механики и комптьютерных наук им. И. И. Воровича
научный руководитель: доцент кафедры ПМП, к.ф.-м.н. Я. М. Демяненко

19 апреля 2018 г.

Содержание

Разметка данных всегда трудоемкий процесс. Поэтому алгоритмы машинного обучения не требующие данного этапа актуальны. Класс вариационных автоэнкодеров позволяет решить данную проблему.

Поставим задачу:

Пусть имеется набор изображений:

$$X = \{I_m\}_{m=1}^{N} \tag{1}$$

Требуется разбить данный набор на K классов и ввести операцию сравнения.
Для произвольного изображения найдем M схожих объектов из множества X, отсортированных по убыванию визуального подобия:

$$I_{input} \notin X, S = \{I_{m_k}\}_{k=1}^{M}$$

Для решения поставленной задачи могут подойти следующие подходы неконтролируемого обучения и обучения с подкреплением:

- Сиамские нейронные сети
- Ключевые точки (не является алгоритмом машинного обучения)
- Автоэнкодеры

Для решения поставленной задачи могут подойти следующие подходы неконтролируемого обучения и обучения с подкреплением:

- Сиамские нейронные сети
- Ключевые точки (не является алгоритмом машинного обучения)

Автоэнкодеры

Определение:

Автоэнкодеры — это нейронные сети прямого распространения, которые восстанавливают входной сигнал на выходе.

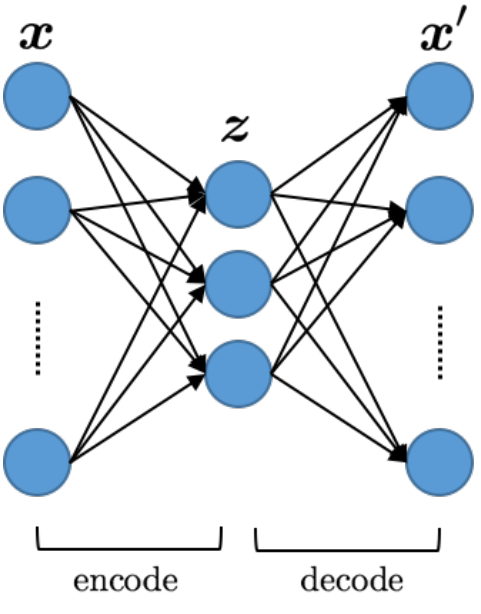

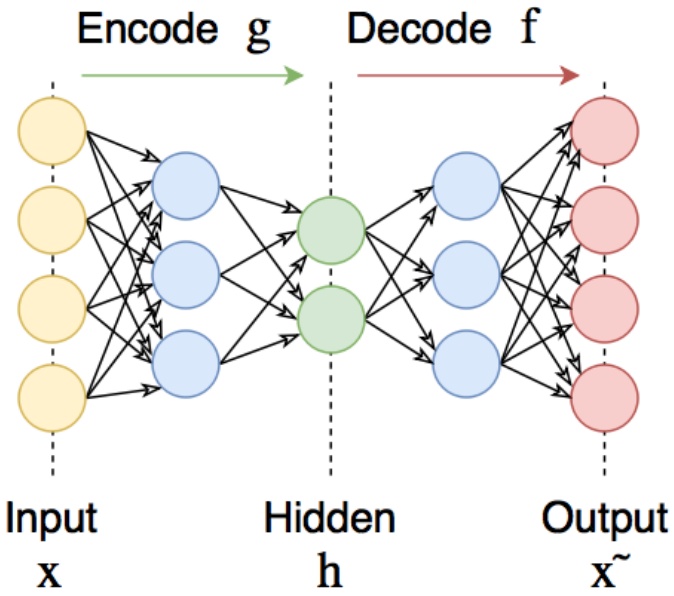

g – энкордер, f – декодер,

x – сигнал, h – код сигнала

$$h = g(x), \; x = f(h)$$

$$x = f(g(x)) \qquad (2)$$

Автоэнкодер при обучении стремится аппроксимировать функцию (2):

$$x = f(g(x)),$$

минимизируя заданный функционал ошибки:

$$\min_{\omega} L(x, f(g(x))), \tag{3}$$

где ω - параметры автоэнкодера

Определение:

Разряженным называется автоэнкодер, для которого критерий обучения включает также минимизацию разреженности $\Omega(h)$ на кодовом слове h:

$$\min_{\omega} L(x, f(g(x))) + \Omega(h),$$

где $\Omega(h)$ - обычный регуляризатор (пусть L_1), $\Omega(h) = \lambda * \|h\|$

Рассмотрим работу декодера как некоторый процесс генерации данных X, зависящий от скрытых переменных Z - случайных величин.
Пусть:

- $P(X)$ - вероятностное распределение изображений
- $P(Z)$ - вероятностное распределение скрытых переменных
- $P(Z|X)$ - вероятностное распределение скрытых параметров при заданном изображении X, рассматривается как энкодер
- $P(X|Z)$ - вероятностное распределение изображений при заданных скрытых переменных Z, рассматривается как декодер

Справедливо:

$$P(X) = \int_Z P(X|Z)P(Z)dZ \tag{4}$$

Пространство может быть высокоразмерным, поэтому напрямую хорошо приблизить интеграл не получится. Воспользуемся тем, что для заданного X соответствует небольшое подмножество Z, а для остальных вероятность $P(X|Z) \to 0$. Также при приближении будем семплировать из “оптимальных” Z.

Чтобы понимать какие Z “оптимальные” вводится распределение $Q(Z|X)$, которое будет показывать для X распределение $Z \sim Q$, которое приводит к этому X.

Пусть $Q(Z|X)$ будет нормальным распределением:

$$Q(Z|X) = N(\mu(X), \Sigma(X)), \tag{5}$$

где μ и Σ - среднее и матрица ковариации для нормального распределения.

Таким образом семплирование скрытых параметров идет из нормального распределения с параметрами μ, Σ. $P(Z|X)$ также является нормальным распределением.

Связь между (4) и (5) выводится из рассмотрения расстояния Кульбака-Лейблера между $Q(Z|X)$ и $P(Z|X)$.

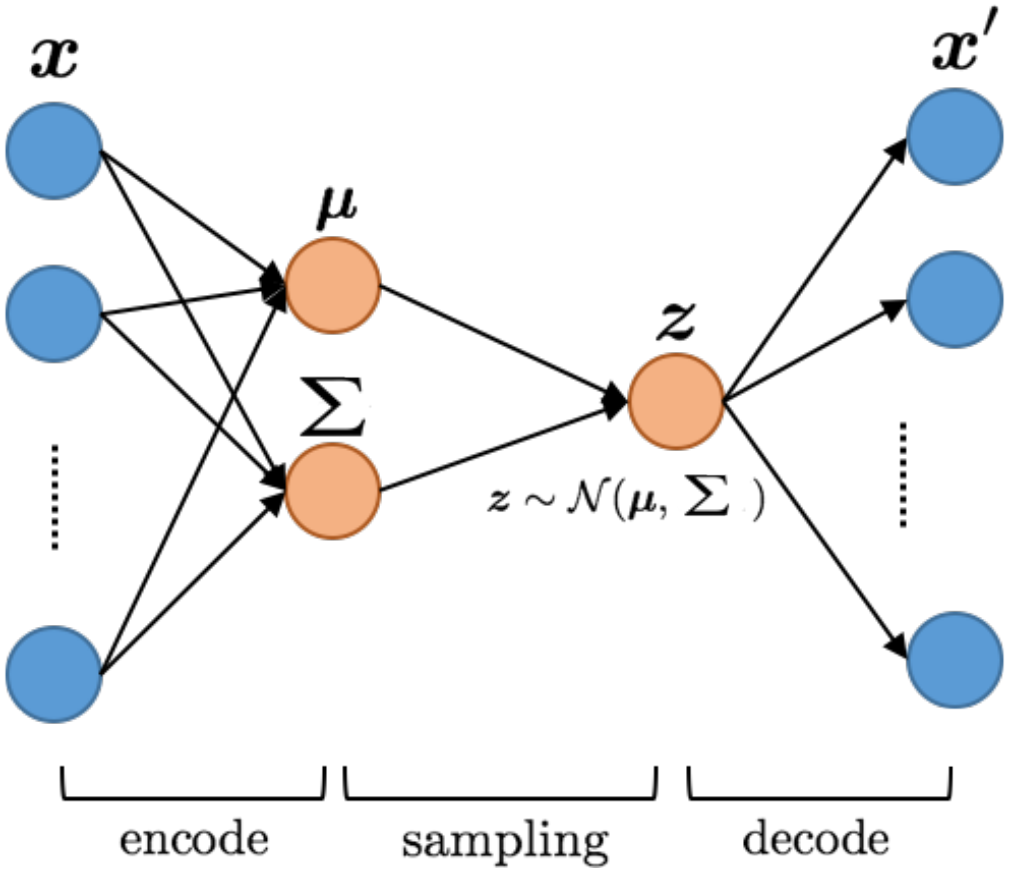
x
x'
μ
Σ
z
$z \sim \mathcal{N}(\mu, \Sigma)$
encode
sampling
decode

Применение вариационных автоэнкодеров к задаче

Архитектура построенного автоэнкодера

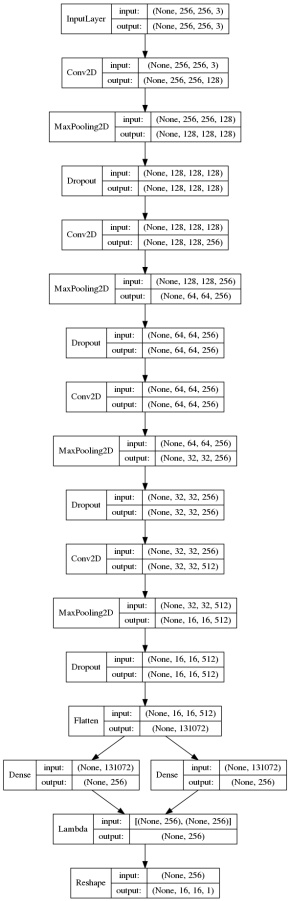

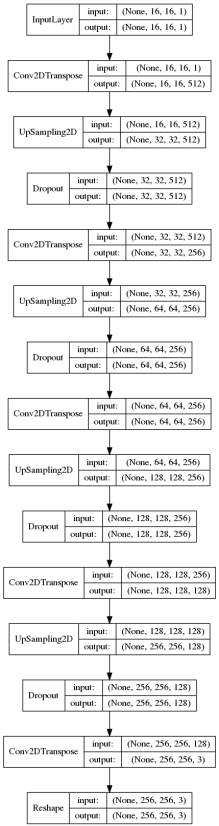

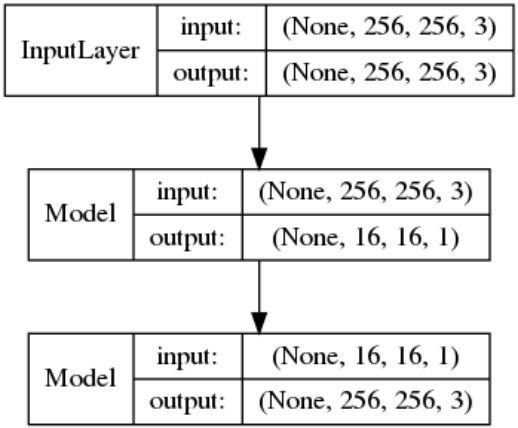

Применение вариационных автоэнкодеров к задаче

Скорость обучения

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_3 (InputLayer)         (None, 256, 256, 3)       0
_________________________________________________________________
Encoder (Model)              (None, 16, 16, 1)         74221184
_________________________________________________________________
Decoder (Model)              (None, 256, 256, 3)       18326659
=================================================================
Total params: 92,547,843
Trainable params: 92,547,843
Non-trainable params: 0
_________________________________________________________________
```

Используемые вычислительные ресурсы:

- CPU: Intel i7-4770K, RAM: 16 Gb
- GPU: Nvidia GTX 1080Ti 11 Gb
- System: Linux Mint 18.2 Sonya x86_64

Время обучения одной эпохи на наборе из 154 644 изображений составляет 5 часов 7 минуты 23 секунды. Оптимальное количество эпох - от 3 (15 часов).

Применение вариационных автоэнкодеров к задаче

Пример работы вариационного автоэнкодера

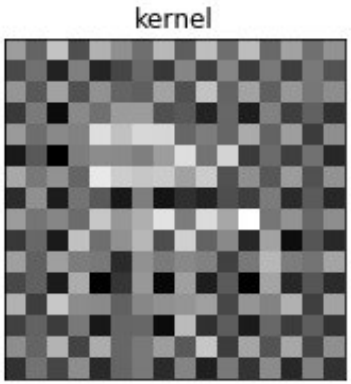

Применение вариационных автоэнкодеров к задаче

Пример работы вариационного автоэнкодера

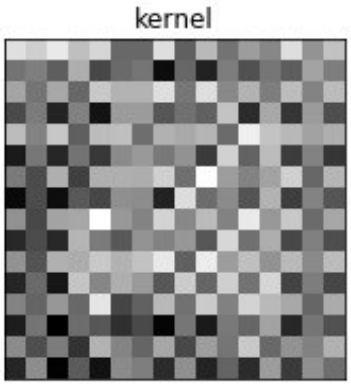

Построим множество H следующим образом:

$$H = \{g(x)|x \in X\}, \tag{6}$$

где X - множество (1), g - вариационный автоэнкодер.

Теперь понизим размерность множества H с помощью метода главных компонент (PCA) или алгоритма распределенного стохастического выделения соседей (t-SNE):

$$\hat{H} = \text{t-SNE}(H),\ \forall h \in \hat{H} \Rightarrow dim(h) = 2 \tag{7}$$

К множеству $\hat{H}$ можно применять классические алгоритмы кластеризации данных, к примеру k-средних, предварительно выбрав количество классов.

Сравнение PCA и t-SNE

PCA

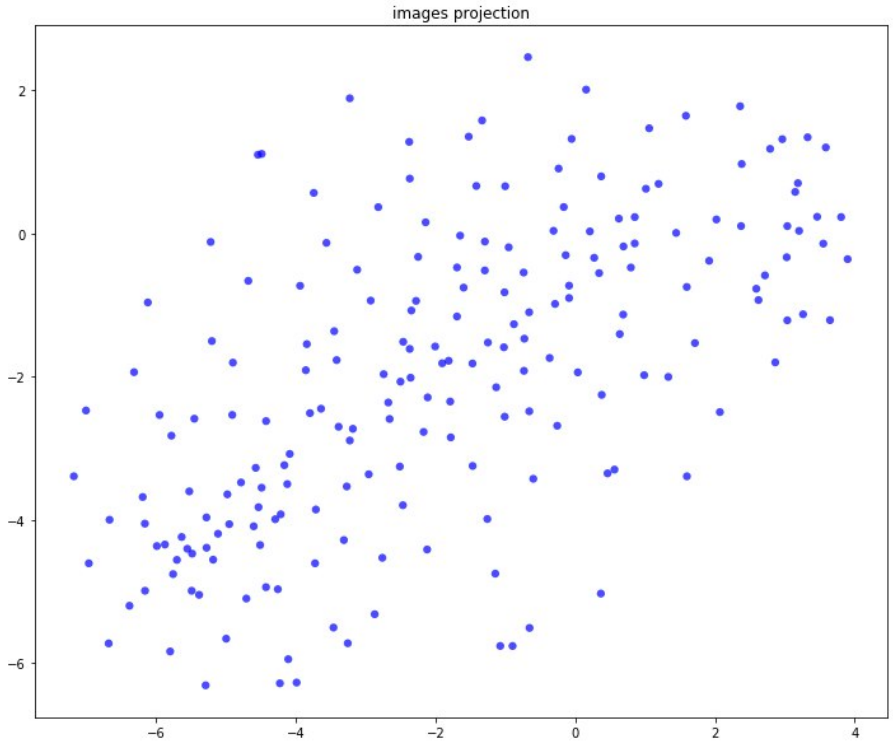

Сравнение PCA и t-SNE

t-SNE

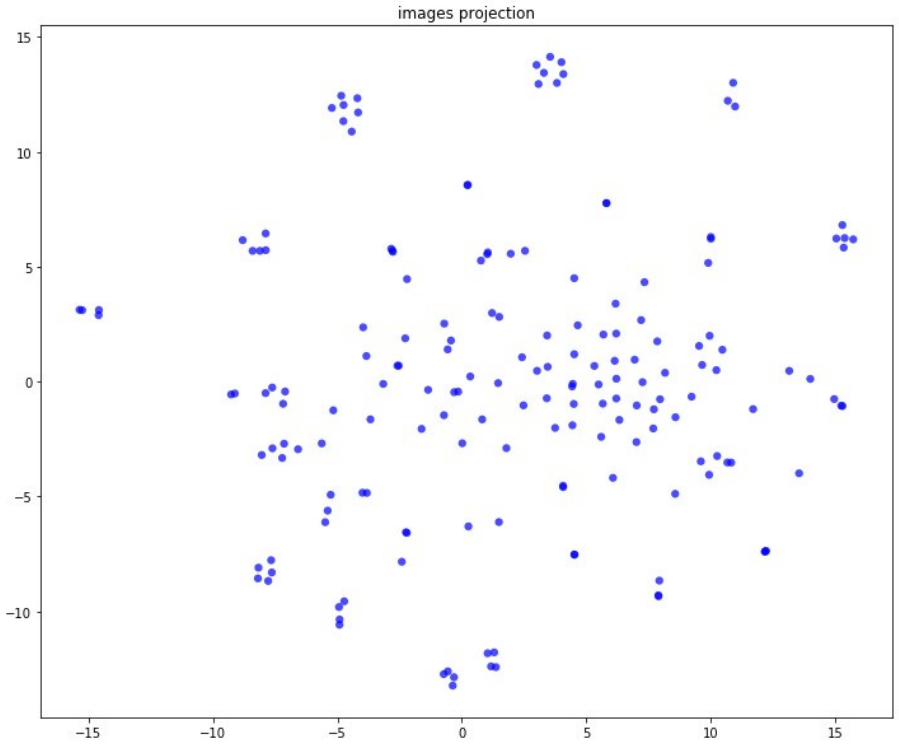

Пусть H, как и в (6):

$$H = \{g(x)|x \in X\}$$

Подействуем энкодером на входное изображение:

$$h_{input} = g(I_{input})$$

Теперь найдем элементы множества S, это будут M-ближайших элемента из множества H по евклидовой метрике.

Список литературы

P. Flash.
Machine learning: The art and science of algorithms that make sense of data.
2018.

I. Goodfellow.
Deep learning.
2018.

S. Haykin.
Neural networks. a comprehensive foundation.
2016.